Bagian A: Analisis Konseptual

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**
   Batch Normalization (BN) utamanya bertujuan menormalisasi aktivasi antar-layer untuk menstabilkan distribusi data internal dan mempercepat konvergensi (Ioffe & Szegedy, 2015). Namun, BN memberikan efek samping berupa regularisasi ringan yang mencegah overfitting, sehingga sering kali menghilangkan kebutuhan akan Dropout.

   Mekanisme Mini-Batch Regularization:
   Efek ini muncul karena BN menghitung mean dan varians berdasarkan mini-batch (subset acak). Karena komposisi batch berbeda tiap iterasi, statistiknya bersifat stokastik (mengandung noise). Noise ini mengubah aktivasi secara tidak deterministik, memaksa neuron untuk tidak menghafal pola spesifik data latih. Mekanisme pengacakan ini sangat mirip dengan cara kerja Dropout (Ioffe & Szegedy, 2015).

   Kondisi Asumsi Tidak Berlaku:
   Asumsi "menghilangkan Dropout" gagal pada fase inferensi, karena BN menggunakan running statistics global yang deterministik (statis), sehingga efek regularisasi hilang. Selain itu, pada batch size sangat kecil (≤2), estimasi statistik menjadi terlalu noisy dan merusak stabilitas training.

   References
   Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of the 32nd International Conference on Machine Learning (ICML), 448–456.

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**
   Penyebab Degradasi:
   Pada plain CNN, penambahan kedalaman memicu degradation problem karena optimasi menjadi sangat tidak stabil. Meskipun secara teori jaringan dalam dapat mempelajari fungsi identitas (identity mapping), dalam praktiknya gradien menghilang atau meledak selama backpropagation, sehingga lapisan tambahan gagal belajar secara efektif (He et al., 2016).

   Formulasi Residual & Aliran Gradien:
   Skip connection mengubah formulasi dengan membiarkan lapisan mempelajari residual $F(x) = H(x) - x$ alih-alih pemetaan penuh $H(x)$. Saat propagasi balik, gradien memiliki jalur pintas (shortcut) untuk mengalir langsung ke lapisan awal tanpa

harus melewati perkalian berantai fungsi aktivasi, sehingga mencegah vanishing gradient.

Kaitan dengan Sesi 02:

Mekanisme ini selaras dengan prinsip mitigasi vanishing gradient pada Sesi 02: dengan menjaga aliran gradien tetap stabil dan hidup, arsitektur residual memungkinkan optimasi konvergen pada jaringan yang sangat dalam tanpa degradasi akurasi.

References

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR.

3.

Dimensi	Feature Extraction	Fine-Tuning
Trainable Params	Sangat sedikit (~5.130 pada ResNet-18, hanya fc head)	Jutaan(sebagian/seluruh backbone dibuka)
Volume data	Efektif pada data sangat terbatas	Memerlukan data lebih besar agar tidak overfit
Komputasi/ memori	Ringan (backward hanya di head)	Berat (backward melewati seluruh/sebagian backbone)
Risiko destruktif	Hampir nol (fitur pretrained beku)	Tinggi jika LR terlalu agresif atau data minim

Feature Extraction optimal ketika data sangat terbatas (<1.000 sampel per kelas) dan domain target secara visual mirip dengan ImageNet (Slide 15). Fine-Tuning mutlak diperlukan ketika domain target berbeda signifikan dari ImageNet dan tersedia data cukup (>2.000 sampel) untuk menyesuaikan representasi tingkat menengah-tinggi tanpa memicu overfit atau merusak fitur bawaan (Slide 16; Howard & Ruder, 2018).

References

Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. ACL.

4. **Kaidah Penerapan Data Augmentation**

   Pertimbangan Metodologis:

   Augmentasi diterapkan eksklusif pada train set sebagai mekanisme regularisasi untuk menciptakan variasi sintetis, memaksa model belajar fitur robust, dan mencegah overfitting. Sebaliknya, augmentasi wajib dinonaktifkan pada

validation/test set karena tujuannya adalah mengevaluasi generalisasi model terhadap distribusi data asli (true distribution). Menambahkan distorsi pada fase evaluasi akan membuat metrik (seperti validation loss untuk early stopping) menjadi bias, fluktuatif, dan gagal merepresentasikan performa inferensi yang sebenarnya (Shorten & Khoshgoftaar, 2019).

Transformasi Tidak Layak & Invariansi Semantik:
Flip Vertikal (RandomVerticalFlip) sangat tidak layak. Prinsip invariansi semantik mensyaratkan transformasi tidak boleh menghasilkan data yang secara realitas mustahil. Hewan peliharaan (kucing/anjing) memiliki orientasi gravitasi tetap (tegak). Citra terbalik vertikal melanggar prior dunia nyata, memaksa model mempelajari fitur anatomi terbalik yang tidak akan pernah ditemui saat produksi, sehingga justru merusak representasi spasial model..

References
Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data, 6(1), 1-48.

5. **Mitigasi Catastrophic Forgetting**
   Mekanisme Terjadinya:
   Catastrophic forgetting terjadi ketika fine-tuning berlangsung terlalu agresif (learning rate besar atau seluruh lapisan dibuka sekaligus), sehingga gradient updates berukuran besar menimpa bobot pretrained secara drastis. Representasi generik dari ImageNet (tepian, tekstur, bentuk) terhapus dan tergantikan fitur domain-specific, membuat model kehilangan kemampuan generalisasinya (Slide 28; McCloskey & Cohen, 1989).

   Dua Strategi Mitigasi:
   - **Differential learning rate:** LR kecil (1e-4) untuk lapisan backbone awal dan LR besar (1e-3) untuk head. Alasan teoritis: lapisan awal menyimpan fitur generik yang masih valid, sehingga langkah update kecil mempertahankannya sementara head beradaptasi cepat.
   - **Gradual unfreezing:** membuka lapisan bertahap dari atas ke bawah. Alasan teoritis: membatasi kapasitas perubahan drastis per tahap, mencegah gradien destruktif merambat ke lapisan rendah (Slide 29; Howard & Ruder, 2018).

   References
   Slide 28–29 (Challenges & Best Practice Transfer Learning)

McCloskey, M., & Cohen, N. J. (1989). Catastrophic Interference in Connectionist Networks. Psychology of Learning and Motivation.
Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. ACL.